

刘瑗玮



手机：18851830977 | 邮箱：liuaw20@mails.tsinghua.edu.cn | 网站：exlaw.github.io

个人简介

我是清华大学软件学院在读博士生（即将毕业），主要研究大语言模型的可靠性与安全性。研究成果已在顶级会议发表多篇论文，获得500余次学术引用，目前主要关注以下三个研究方向：

- 大语言模型水印技术：致力于在模型输出中嵌入可检测的特征标记，实现内容溯源与版权保护，防范模型滥用。
- 模型安全性提升：通过对齐技术与红队测试等方法增强模型安全性，系统性地发现和解决潜在安全隐患。
- 自然语言转 SQL：研究如何提高自然语言到 SQL 的转换准确性，重点解决复杂数据库架构下的查询转换问题。

教育背景

- 清华大学软件学院博士，软件工程专业，导师：[闻立杰](#)副教授 2020.09 - 至今
 - 南京大学软件学院本科，软件工程专业 2016.09 - 2020.07
- GPA：4.6 / 5.00 排名：5/220

实习经历

- 伊利诺伊大学芝加哥分校 | [BDSC Lab](#) 访问学者 2024.7 - 至今
 - 导师：[Philip S. Yu](#) 教授 (ACM Fellow, IEEE Fellow)
 - 主要贡献：研究带水印大语言模型的隐私性，特别是用户对其的可识别性
- 香港中文大学 | [MISC Lab](#) 访问学者 2023.7 - 2024.5
 - 导师：[Irwin King](#) 教授 (IEEE Fellow)
 - 主要贡献：开发了一种用于大语言模型的不可伪造的公开可验证水印，发表在 ICLR 2024。并撰写了一篇关于大语言模型时代文本水印的综述论文，已被 ACM Computing Surveys 接收。
- 苹果公司 | [AIML 团队](#) 研究实习生 2023.3 - 2024.9
 - 导师：[曹蒙](#)博士
 - 主要贡献：1) 开发了基于大语言模型的自动属性识别方法，用于提示词难度评估 2) 提出了一种无需人工标注偏好数据的大语言模型安全对齐方法，发表在 ACL 2024 3) 提出 TIS DPO：基于估计权重的令牌级重要性采样直接偏好优化方法

第一作者论文汇总

如果您对我作为第一作者的研究贡献感兴趣（这对某些机构的招聘可能很重要），以下是我第一作者论文发表的汇总（不包含共同一作排名靠后的论文）：

- 顶级会议论文：4 篇 ICLR 论文，1 篇 ACL 论文，1 篇 SIGKDD 论文，1 篇 EMNLP 论文，以及 1 篇 ACL(Findings) 论文
- 期刊论文：1 篇 ACM Computing Surveys 论文（影响因子：23.8）

科研成果（大模型水印方向）

- [A Semantic invariant Robust Watermark for Large Language Models](#) 2024
 - [Aiwei Liu](#), [Leyi Pan](#), [Xuming Hu](#), [Shiao Meng](#), [Lijie Wen](#)
 - ICLR 2024 (谷歌学术计算机科学会议排名第3位)
- [An Unforgeable Publicly Verifiable Watermark for Large Language Models](#) 2024
 - [Aiwei Liu](#), [Leyi Pan](#), [Xuming Hu](#), [Shu'ang Li](#), [Lijie Wen](#), [Irwin King](#), [Philip S. Yu](#)
 - ICLR 2024 (谷歌学术计算机科学会议排名第3位)


- 🔗 **Can Watermarked LLMs be Identified by Users via Crafted Prompts?** 2025
 - **Aiwei Liu**, Sheng Guan, Yiming Liu, Leyi Pan, Yifei Zhang, Liancheng Fang, Lijie Wen, Philip S. Yu, Xuming Hu
 - ICLR 2025 (谷歌学术计算机科学会议排名第3位)
- 🔗 **A Survey of Text Watermarking in the Era of Large Language Models** 2024
 - **Aiwei Liu***, Leyi Pan*, Yijian Lu, Jingjing Li, Xuming Hu, Xi Zhang, Lijie Wen, Irwin King, Hui Xiong, Philip S. Yu
 - ACM Computing Surveys (影响因子: 23.8, 计算机科学理论与方法领域排名第 1/143 位)
- 🔗 **MarkLLM: An Open-Source Toolkit for LLM Watermarking** 2024
 - Leyi Pan, **Aiwei Liu**[†] (项目负责人), Zhiwei He, Zitian Gao, Xuandong Zhao, Yijian Lu, Binglin Zhou, Shuliang Liu, Xuming Hu, Lijie Wen, Irwin King, Philip S. Yu
 - 已被 EMNLP 2024 Demo Track 接收
 - GitHub 仓库已获得超过 300 颗星标, 11 位开源贡献者, 展示了显著的社区影响力
- 🔗 **An Entropy-based Text Watermarking Detection Method** 2024
 - Yijian Lu, **Aiwei Liu**, Dianzhi Yu, Jingjing Li, Irwin King
 - 已被 ACL 2024 接收
- 🔗 **WaterSeeker: Efficient Detection of Watermarked Segments in Large Documents** 2025
 - Leyi Pan, **Aiwei Liu**, Yijian Lu, Zitian Gao, Yichen Di, Lijie Wen, Irwin King, Philip S. Yu
 - 已被 NAACL 2025 Findings 接收
- 🔗 **On the Cross-lingual Consistency of Text Watermark for Large Language Models** 2024
 - Zhiwei He, Binglin Zhou, Hongkun Hao, **Aiwei Liu**, Xing Wang, Zhaopeng Tu, Zhuosheng Zhang, Rui Wang
 - 已被 ACL 2024 接收 (口头报告)

📁 科研成果 (大模型安全性提升方向)

- 🔗 **TIS-DPO: Token-level Importance Sampling for Direct Preference Optimization With Estimated Weights** 2025
 - **Aiwei Liu**, Haoping Bai, Zhiyun Lu, Yanchao Sun, Xiang Kong, Xiaoming Wang, Jiulong Shan, Albin Madappally Jose, Xiaojiang Liu, Lijie Wen, Philip S. Yu, Meng Cao
 - ICLR 2025 (谷歌学术计算机科学会议排名第3位)
- 🔗 **Direct Large Language Model Alignment Through Self-Rewarding Contrastive Prompt Distillation** 2024
 - **Aiwei Liu**, Haoping Bai, Zhiyun Lu, Xiang Kong, Simon Wang, Jiulong Shan, Meng Cao, Lijie Wen
 - 已被 ACL 2024 接收
- 🔗 **Character-level White-Box Adversarial Attacks against Transformers via Attachable Subwords Substitution** 2022
 - **Aiwei Liu**, Honghai Yu, Xuming Hu, Shu'ang Li, Li Lin, Fukun Ma, Yawen Yang, Lijie Wen
 - 已被 EMNLP 2022 接收

📁 科研成果 (自然语言转 SQL 方向)

- 🔗 **Semantic Enhanced Text-to-SQL Parsing via Iteratively Learning Schema Linking Graph** 2022
 - **Aiwei Liu**, Xuming Hu, Li Lin, Lijie Wen
 - 已被 SIGKDD 2022 接收

 Exploring the Compositional Generalization in Context Dependent Text-to-SQL Parsing2023

- **Aiwei Liu**, Wei Liu, Xuming Hu, Shuang Li, Fukun Ma, Yawen Yang, Lijie Wen
- 已被 **ACL 2023 Findings** 接收

 A Comprehensive Evaluation of ChatGPT’s Zero-shot Text-to-SQL Capability2023

- **Aiwei Liu**, Xuming Hu, Lijie Wen, Philip S Yu
- 该工作已获得超过**100 次引用**，展示了显著的学术影响力

奖项与荣誉

🏆 清华之友-途游奖学金（一等）	2024
🏆 清华之友-沈阳浑南英才奖学金（二等）	2022
🏆 南京大学优秀毕业生	2020
🏆 中国电子科技集团奖学金	2019
🏆 南京大学优秀共青团干标兵	2019
🏆 国家奖学金	2018
🏆 海南航空奖学金	2017

🎧 学术服务

会议审稿人

- The International Conference on Learning Representations (ICLR)
- The Annual Meeting of the Association for Computational Linguistics (ACL)
- The Annual Conference on Empirical Methods in Natural Language Processing (EMNLP)
- The Annual Conference of the North American Chapter of the Association for Computational Linguistics (NAACL)
- The Annual Conference of the European Chapter of the Association for Computational Linguistics (EACL)
- The ACM WWW International World Wide Web Conference (WWW)
- The ACM International Conference on Multimedia (MM)


工作坊（workshop）组织

- [AAAI 2025 Workshop on Preventing and Detecting LLM Generated Misinformation \(PDLM\)](#)联合组织者

📖 教学经历

大语言模型生成误导信息的预防与检测	July 2024
SIGIR 2024 Tutorial <ul style="list-style-type: none">• 作为主讲人在第 47 届国际 ACM SIGIR 会议上进行大语言模型生成误导信息预防与检测技术的教程讲解• 教程网站：https://sigir24-llm-misinformation.github.io/	
创新人才与大学文化	2021
助教，清华大学 <ul style="list-style-type: none">• 协助课程教学，组织学生讨论，为课程相关项目提供支持	
操作系统	2018
助教，南京大学 <ul style="list-style-type: none">• 指导实验课程，批改作业，为学生理解复杂的操作系统概念提供一对一辅导	

其他发表论文

 GDA: Generative Data Augmentation Techniques for Relation Extraction Tasks2023

- Xuming Hu*, **Aiwei Liu*** (共同一作), Zeqi Tan, Xin Zhang, Chenwei Zhang, Irwin King, Philip S. Yu

- 已被 ACL 2023 Findings 接收
- ✂ **Mitigating Modality Prior-Induced Hallucinations in Multimodal Large Language Models via Deciphering Attention Causality** 2024
 - Guanyu Zhou, Yibo Yan, Xin Zou, Kun Wang, **Aiwei Liu**, Xuming Hu
 - 已被 ICLR 2025 接收
- ✂ **RAPL: A Relation-Aware Prototype Learning Approach for Few-Shot Document-Level Relation Extraction** 2023
 - Shiao Meng, Xuming Hu, **Aiwei Liu**, Shu'ang Li, Fukun Ma, Yawen Yang, Lijie Wen
 - 已被 EMNLP 2023 接收
- ✂ **AMR-based network for aspect-based sentiment analysis** 2023
 - Fukun Ma, Xuming Hu, **Aiwei Liu**, Yawen Yang, Philip S. Yu, Lijie Wen
 - 已被 ACL 2023 接收
- ✂ **CHEF: A Pilot Chinese Dataset for Evidence-Based Fact-Checking** 2022
 - Xuming Hu, Zhijiang Guo, Guanyu Wu, **Aiwei Liu**, Lijie Wen, Philip S. Yu
 - 已被 NAACL 2022 接收
- ✂ **A Multi-level Supervised Contrastive Learning Framework for Low-Resource Natural Language Inference** 2023
 - Shu'ang Li, Xuming Hu, Li Lin, **Aiwei Liu**, Lijie Wen, Philip S. Yu
 - IEEE/ACM Transactions on Audio, Speech, and Language Processing
- ✂ **Improving Open Relation Extraction With Search Documents Under Self-Supervisions** 2023
 - Xuming Hu, Zhaochen Hong, Chenwei Zhang, **Aiwei Liu**, Shiao Meng, Lijie Wen, Irwin King, Philip S. Yu
 - IEEE Transactions on Knowledge and Data Engineering
- ✂ **Refiner: Restructure Retrieval Content Efficiently to Advance Question-Answering Capabilities** 2024
 - Zhonghao Li, Xuming Hu, **Aiwei Liu**, Kening Zheng, Sirui Huang, Hui Xiong
 - 已被 EMNLP 2024 Findings 接收
- ✂ **Entity-to-Text based Data Augmentation for various Named Entity Recognition Tasks** 2023
 - Xuming Hu, Yong Jiang, **Aiwei Liu**, Zhongqiang Huang, Pengjun Xie, Fei Huang, Lijie Wen, Philip S. Yu
 - 已被 ACL 2023 Findings 接收
- ✂ **Enhancing Cross-lingual Natural Language Inference by Soft Prompting with Multilingual Verbalizer** 2023
 - Shuang Li, Xuming Hu, **Aiwei Liu**, Yawen Yang, Fukun Ma, Philip S. Yu, Lijie Wen
 - 已被 ACL 2023 Findings 接收
- ✂ **Gaussian prior reinforcement learning for nested named entity recognition** 2023
 - Yawen Yang, Xuming Hu, Fukun Ma, Shuang Li, **Aiwei Liu**, Lijie Wen, Philip S. Yu
 - 已被 ICASSP 接收
- ✂ **On the Robustness of Document-Level Relation Extraction Models to Entity Name Variations** 2024
 - Shiao Meng, Xuming Hu, **Aiwei Liu**, Fukun Ma, Yawen Yang, Shuang Li, Lijie Wen
 - 已被 ACL 2024 Findings 接收

- 🔗 ChatCite: LLM Agent with Human Workflow Guidance for Comparative Literature Summary 2024
- Yutong Li, Lu Chen, **Aiwei Liu**, Kai Yu, Lijie Wen
 - 已被 COLING 2025 接收
- 🔗 Entropy-Based Decoding for Retrieval-Augmented Large Language Models 2024
- Zexuan Qiu, Zijong Ou, Bin Wu, Jingjing Li, **Aiwei Liu**, Irwin King
 - 已被 NAACL 2025 接收

其他预印本论文

- 🔗 Interpretable Contrastive Monte Carlo Tree Search Reasoning 2024
- Zitian Gao, Boye Niu, Xuzheng He, Haotian Xu, Hongzhang Liu, **Aiwei Liu**, Xuming Hu, Lijie Wen
- 🔗 Entropy-Based Decoding for Retrieval-Augmented Large Language Models 2024
- Liancheng Fang, **Aiwei Liu**, Hengrui Zhang, Henry Peng Zou, Weizhi Zhang, Philip S. Yu
 - 已被 TRL@NeurIPS 2024 接收